

¿Quiénes son los pacientes más caros? Identificación de perfiles de alto costo en la salud pública mediante datos GRD

*¿Existen perfiles clínicos de pacientes asociados a alto consumo
de recursos hospitalarios?*

Alumnas:

- Josefa Lara
- Catalina Toledo

Facultad de Ingeniería, Universidad del Desarrollo

Profesor: Cristian Garcia

Ayudante: Benjamín Bennet

11 de Mayo, 2026

Introducción

Ante la presión asistencial actual, el sistema público chileno requiere optimizar sus recursos mediante la base de Egresos Hospitalarios y el sistema GRD, validado por el MINSAL (2024). Esta herramienta permite estandarizar la asignación presupuestaria al agrupar pacientes por similitud clínica y consumo de insumos. Como señalan Averill et al. (1998), la arquitectura APR-DRG es indispensable para evaluar con precisión la severidad y el riesgo de mortalidad.

El análisis de estos datos es clave para entender la distribución del gasto, ya que el modelo chileno valoriza los egresos según costos de producción estimados. Este proyecto se enfoca en el "Peso Relativo" (promedio sistémico 1.0) para identificar perfiles con mayor impacto financiero. Actualmente, existe un vacío en la caracterización de perfiles que exceden dicho promedio, lo que limita la eficiencia en centros de alta complejidad por lo que esta investigación define operativamente al 'Paciente de Alto Costo' como aquel situado en el cuartil superior del gasto (P75), analizando tanto el episodio aislado como la recurrencia del beneficiario.

Mientras Reinhardt (2006) destaca la opacidad de los costos hospitalarios, Castillo-Riquelme et al. (2021) validan la valorización de egresos como la solución técnica adoptada en Chile, justificando el uso del Peso Relativo en este estudio. Finalmente, para lograr una gestión proactiva, es importante el uso de analítica de datos masivos. Utilizando una muestra de 1.048.015 registros, esta investigación busca determinar cómo la edad, severidad, ubicación y diagnósticos complejos definen al "paciente de alto costo", aportando evidencia para la sostenibilidad de la red pública.

Pregunta de Investigación: ¿Existen perfiles clínicos de pacientes asociados a un alto consumo de recursos hospitalarios en el sistema de salud pública chileno?

Variables y Metodología:

El estudio utiliza el Peso Relativo y el Costo Proxy como variables dependientes para cuantificar el consumo de recursos. Se identifican la Severidad, la Edad, los Días de Estadía y el Sexo como variables explicativas críticas.

La investigación adopta un enfoque multinivel:

- **Análisis Exploratorio (EDA):** Caracterización de la distribución del gasto y detección de asimetrías mediante el Percentil 75 (P75) para definir operativamente el "Alto Costo".
- **Inferencia Estadística:** Empleo del test de Kruskal-Wallis para contrastar la igualdad de distribuciones de gasto acumulado por beneficiario, permitiendo identificar heterogeneidad entre los perfiles de SEXO × FRANJA_ETARIA.
- **Modelamiento Predictivo:** Uso de una regresión lineal múltiple (OLS) para cuantificar el impacto marginal de cada factor clínico y territorial en el costo final, validando la

significancia de la severidad nivel 3 y las estadías prolongadas como determinantes del presupuesto hospitalario.

Justificación del Proyecto

Relevancia: Ante la crisis de demanda en la salud pública chilena, este estudio busca identificar perfiles de alto costo mediante el análisis de severidad clínica y variables sociodemográficas. El objetivo es optimizar la programación quirúrgica y la asignación de recursos, diferenciando entre la complejidad clínica intrínseca y las ineficiencias de gestión. Al caracterizar la "cola derecha" de la distribución del gasto, el proyecto busca asegurar la sostenibilidad financiera y una atención oportuna basada en el riesgo del paciente.

Factibilidad: La factibilidad técnica se sustenta en el acceso y procesamiento de 1.048.015 registros de egresos hospitalarios (GRD). La metodología de trabajo, que integra el uso de Python sobre esta base masiva, permite realizar inferencias estadísticas sólidas y comparaciones robustas entre centros y regiones. La integración de tablas maestras estandarizadas del Ministerio de Salud asegura una interpretación precisa de diagnósticos y establecimientos, minimizando sesgos y permitiendo la consolidación de datos por ID BENEFICIARIO para un análisis longitudinal del gasto.

Relación con los Objetivos del Curso: Este proyecto cumple con las competencias del programa al abordar el procesamiento de datos a gran escala, desde la limpieza avanzada hasta la creación de Data Frames para modelos predictivos y de asociación. Se aplica estadística inferencial mediante el uso de estimadores no paramétricos (Kruskal-Wallis) y modelos de regresión lineal múltiple para cuantificar la eficiencia hospitalaria en un contexto de alto impacto social.

Finalmente, el uso de cuadernos computacionales para integrar narrativa técnica y visualizaciones, como el análisis de concentración de gasto y matrices de correlación, fortalece la comunicación de hallazgos complejos, utilizando la analítica de datos para resolver problemas críticos en salud y gestión de procesos.

Descripción de los Datos y Glosario

Origen del Dataset: Este proyecto emplea registros de Egresos Hospitalarios (GRD) del DEIS, dependiente del Ministerio de Salud de Chile. Mediante el cruce con Tablas Maestras de Establecimientos, se vinculan códigos institucionales con nombres y ubicaciones geográficas para asegurar la trazabilidad de la red.

Descripción del Dataset:

Este estudio analiza egresos hospitalarios individuales del año 2024, procesando 1.048.015 registros del DEIS/MINSAL. De las 129 columnas originales, se seleccionaron variables clave

para el modelado de costos: el Peso Relativo como variable dependiente, junto con la severidad clínica, días de estadía, edad y sexo como independientes.

Tamaño y Calidad de los Datos:

Tras una limpieza rigurosa de inconsistencias administrativas, la muestra final permite inferencias de alta potencia estadística. La inclusión del identificador de beneficiario facilita consolidar el gasto por persona para identificar perfiles de "Alto Costo".

Etapas	Número de registros
Dataset original DEIS 2024	1.048.575
Registros con comuna y días válidos (análisis):	1,048,015
Duplicados en subconjunto	966
Filas sin región mapeable	378
Nulos en ESPECIALIDAD INTERVENCIÓN	450.186

Tabla 1, Limpieza de datos

Limpieza y Preparación de Datos: La limpieza de datos garantizó la integridad estadística mediante una selección rigurosa de variables y un filtrado que eliminó inconsistencias críticas (ausencia de región, valores no numéricos o sexo no especificado). Las variables DIAS, ESTADIA y EDAD se re-calcularon tras validar fechas clave de egreso para mitigar errores de origen.

Se integró COSTO PROXY para aplicar reglas de ALTO PESO y ALTO COSTO, definiendo este último mediante el Percentil 75 (P75). Una auditoría final sobre 1.048.015 registros confirmó la unicidad y robustez de la base para el modelamiento y pruebas de hipótesis.

Naturaleza de los Datos: Posee naturaleza administrativa debido a los registros institucionales del DEIS/MINSAL, transversal al presentar un análisis estático de los egresos hospitalarios del año 2024 y clínica debido a que son datos hospitalarios de pacientes.

Atributo	Detalle
Fuente de datos	DEIS (Ministerio de Salud de Chile)
Periodo de análisis	2024

Registros originales	> 1.048.575 filas
Registros tras limpieza	1.048.015 filas
Columnas totales	129
Unidad de análisis	Estadía Hospitalaria y Severidad por región.

Tabla 2, *Resumen del Tamaño y Origen del Dataset*

Análisis Exploratorio de Datos (EDA)

El análisis descriptivo indica que el Peso Relativo promedio supera 1.0, reflejando una complejidad clínica superior a la media pública. La mediana de estadía, muy inferior al promedio, confirma un sesgo a la derecha; esto demuestra que una minoría de pacientes críticos concentra el mayor consumo de días-cama.

Variable	Mean	Std	Mediana	Max	P75
Peso Relativo	5.56	11.96	0.69	206.46	10.126
Días Estadía	5.69	12.13	2.00	661.00	6.0
Edad	46.06	25.53	47.00	109.00	68
Costo Proxy	\$2.226.708	\$4.786.549	\$276.600	\$82.584.400	\$4.050.400

Tabla 3, *Estadísticas descriptivas dataframe*

Análisis Descriptivo e Interpretación de Hallazgos

La interpretación integral de los hallazgos revela una estructura de gasto altamente asimétrica, con una marcada diferencia entre la media y la mediana (0.69) que confirma un sesgo a la derecha extremo, donde, a pesar de que el 90% de los casos presenta un peso inferior a 15.31, la existencia de un valor máximo de 206.46 valida la decisión metodológica de centrar el estudio en el Percentil 75 (P75) para capturar los perfiles de mayor impacto. Esta disparidad se refleja también en la estancia hospitalaria, cuya mediana de apenas 2 días contrasta con un promedio de 5.69 días impulsado por casos críticos extremos de hasta 661 días de ocupación de cama. Demográficamente, el promedio de edad de 46 años y el amplio rango de 0 a 109 años permiten identificar costos críticos asociados a la fragilidad biológica en ambos extremos del ciclo vital, consolidando al Nivel 3 de severidad como el factor clínico disruptivo por excelencia,

responsable de generar los valores atípicos y las mayores desviaciones presupuestarias en el Peso Relativo del sistema público.

Visualizaciones exploratorias

Se presentan gráficos clave sobre la investigación, con detalles adicionales en el anexo C.

Este gráfico de barras visualiza cómo escala el consumo de recursos a medida que el paciente permanece más tiempo en el hospital. Se observa un incremento escalonado y consistente. Mientras un paciente de "0 a 2 días" tiene una mediana de peso relativo baja (~ 0.5), aquellos con estancias superiores a 31 días disparan su mediana por encima de 4.0.

El salto más significativo ocurre al superar los 7 días, donde el peso relativo prácticamente se duplica, marcando la frontera entre un egreso estándar y uno de alta complejidad.




Gráfico 1 y 2, Relaciones entre variables.

A continuación se presenta un mapa de calor que mide la fuerza de la relación lineal entre las variables numéricas del sistema. Existe una correlación positiva moderada-fuerte (0.68) entre DIAS ESTADIA y el COSTO APROXIMADO. Esto confirma que el tiempo de ocupación de cama es un predictor directo del gasto, aunque no es el único.

La EDAD muestra correlaciones muy bajas con el costo y el peso (cercanas a 0.08), lo que sugiere que el costo no aumenta simplemente por "ser más viejo", sino por la severidad clínica asociada, validando la necesidad de un análisis multivariante.




Gráfico 3, Correlación de Pearson entre variables numéricas principales

La relación entre la estancia hospitalaria y el consumo de recursos se manifiesta de manera bidimensional mediante el cruce de la Matriz de Pearson y el análisis de Tramos de Estadía.

La matriz de correlación de Pearson establece una asociación positiva moderada-fuerte de **0.68** entre los *DÍAS ESTADÍA* y el *COSTO APROXIMADO*. Este valor estadístico confirma que la permanencia en cama actúa como el predictor lineal más robusto del gasto, superando significativamente la influencia aislada de variables como la edad o el sexo.

Al contrastar esta correlación con el comportamiento observado en los gráficos, se evidencia que la relación no es constante. Mientras que la matriz de Pearson ofrece un promedio de la fuerza de asociación, el análisis por tramos revela puntos de inflexión críticos:

- **El salto de la primera semana:** Superar los 7 días duplica la mediana del peso relativo, marcando la transición de atención estándar a alta complejidad.
- **Efecto de Cronicidad:** En estadías superiores a 31 días, la mediana del peso relativo excede 4.0, demostrando que este segmento crítico tracciona desproporcionadamente la correlación de 0.68.

Test de Hipótesis

En esta sección se evalúa si existen diferencias significativas en el consumo de recursos hospitalarios cuando se analiza al paciente de forma integral, consolidando todos sus episodios de egreso durante el periodo 2024.

Definición de la Unidad Analítica y Variables

A diferencia de los análisis descriptivos previos basados en eventos, la unidad de análisis para este contraste es el ID BENEFICIARIO.

- **Variable Dependiente:** Gasto Total Proxy Acumulado (sumatoria de COSTO APROXIMADO de todas las atenciones del individuo).
- **Factores de Agrupación:** Se definen diez perfiles basados en la interacción Sexo × Franja Etaria (0–1, 2–17, 18–39, 40–59, 60 y más años).

Hipótesis General

El gasto total acumulado por beneficiario en el sistema de salud pública no se distribuye de manera equitativa entre los diferentes grupos demográficos, sugiriendo que la carga financiera institucional está condicionada por el perfil de edad y sexo del paciente.

- **Hipótesis Nula (H0):** Las distribuciones del gasto total proxy por beneficiario son iguales entre los diez perfiles de SEXO x FRANJA_ETARIA
 - $H_0: F_1 = F_2 = \dots = F_{10}$
- **Hipótesis Alternativa (H1):** Al menos uno de los perfiles presenta un Peso Relativo promedio significativamente distinto a los demás.
- **Variable Analizada:** Al menos un perfil demográfico presenta una distribución de gasto acumulado diferente (ya sea por una mediana más alta o una cola de gasto más pesada), indicando un comportamiento de consumo de recursos significativamente distinto.
- **Nivel de Significancia:** $\alpha=0.05$.
- **Tipo de Test:** Test de Kruskal-Wallis

Justificación e Interpretación

El uso de Kruskal-Wallis garantiza que las diferencias detectadas entre perfiles demográficos sean estadísticamente válidas y no un artefacto de la distribución irregular de los costos, permitiendo una conclusión sólida sobre qué grupos de la población traccionan realmente la carga financiera del sistema público.

Un p-valor bajo rechaza igualdad entre perfiles SEXO × FRANJA_ETARIA el orden relativo típico del gasto acumulado por persona y apunta a heterogeneidad de perfiles financieros ante el proxy usado en el proyecto. Para ¿quién pesa más dentro de ese mapa?, ordenar las filas por mediana o ‘gasto_total’ (CSV). La concentración muestra cuántos pocos usuarios cargan gran parte del gasto observado sin distinguir causa clínica. La proporción episodio-máximo / total

cercana a 1 para muchos sugiere un egreso muy caro dominante, valores bajos repartidos indican más persistencia multisalida.

Resultados Preliminares

En esta etapa, el análisis transita de la unidad "egreso" a la unidad "beneficiario", permitiendo capturar la carga financiera real que representa cada individuo para el sistema durante el periodo 2024. Se consolidó una cohorte de 823.822 personas distintas, quienes en conjunto generaron un gasto total promedio de \$2.333.623.608.920 pesos chilenos.

Resultado del Test de Kruskal-Wallis

Se aplicó un único contraste de Kruskal-Wallis para evaluar la igualdad de distribuciones de gasto acumulado entre los 10 perfiles definidos por la interacción SEXO × FRANJA_ETARIA.

Métrica	Valor
Estadístico H	115.115,24
K grupos	10
p-valor	< 0,0001 (0.0000e+00)
Nivel de significancia (α)	0,05
Grados de libertad (k-1)	9

Tabla 4, Tabla de Resultados de test Kruskal-Wallis.

Discusión: Perfiles de Gasto y Concentración de Recursos

El análisis revela que el gasto en la red pública chilena sigue patrones demográficos y de concentración predecibles. El estadístico Kruskal-Wallis fue $H= 115.115$, con un p valor < 0,001El perfil crítico lo lideran hombres mayores de 60 años, cuyo gasto acumulado (\$606.000) supera en un 57% al femenino, sugiriendo patologías más complejas. Existe una extrema concentración: el 20% de los pacientes genera el 79,6% del gasto total, validando la Ley de Pareto en salud.

La mayoría del presupuesto de alto costo se destina a episodios agudos únicos catastróficos, más que a reingresos recurrentes. Territorialmente, el gasto se concentra en comunas densas como Puente Alto y Maipú, además de zonas extremas como Aysén por factores de infraestructura regional. En conclusión, el sistema requiere transitar hacia una gestión basada en el riesgo del beneficiario, enfocada en hombres de la tercera edad y episodios de alta intensidad.

Modelo de Regresión lineal

Se aplicó un modelo OLS para medir el impacto de variables demográficas y clínicas en el Peso Relativo ($\$F = 23.490$, $p < 0.001\$$).

Predictores Críticos

- **Severidad:** Es el factor principal; el Nivel 3 incrementa el peso en 10.62 unidades, confirmando que la complejidad clínica impulsa el costo.
- **Estadía:** Cada día adicional suma 0.33 unidades ($p < 0.001$), afectando la planificación de recursos.
- **Demografía:** La edad tiene un impacto positivo marginal (0.02/año), mientras que los hombres tienden a un mayor peso relativo (coeficiente mujer: -1.12).

Perfil Territorial

- **Zonas Extremas:** Aysén (0.79) y Los Ríos (0.78) son las más costosas, sugiriendo brechas en especialistas y logística.
- **Región Metropolitana:** Su coeficiente (0.39) refleja la concentración de casos derivados de alta complejidad.

Diagnóstico del Modelo

- **Ajuste:** El R^2 de 0.32 muestra una capacidad predictiva sólida en salud pública. Significancia: Todos los predictores principales poseen un p-valor de 0.000, validando los resultados.

Próximos Pasos

Para concluir el proyecto, el equipo realizará:

- **Mejora del Modelo:** Incluir interacciones entre estadía y severidad.
- **Análisis Regional:** Investigar la alta complejidad en zonas extremas.
- **Validación Estadística:** Testear heterocedasticidad y multicolinealidad.
- **Recomendaciones:** Traducir hallazgos en guías de gestión hospitalaria.

Bibliografía:

1. Averill, R. F., Goldfield, N. I., Muldoon, J., Steinbeck, B. A., & Grant, T. M. (2002). A closer look at all-patient refined DRGs. *Journal of AHIMA*, 73(1), 46–50. Link: <https://hcup-us.ahrq.gov/db/nation/nis/APR-DRGsV20MethodologyOverviewandBibliography.pdf>
2. Castillo-Riquelme, M., et al. (2021). Análisis de costos y eficiencia en la red de hospitales públicos de Chile. *Revista Médica de Chile*.
3. Ministerio de Salud de Chile [MINSAL]. (2024). Manual de normas y procedimientos de la Unidad de Gestión de Egresos y GRD.
4. Raghupathi, W., & Raghupathi, V. (2014). Big data analytics in healthcare: Promise and potential. *Health Information Science and Systems*.
5. Reinhardt, U. E. (2006). The pricing of hospital services: Chaos behind a veil of secrecy. *Health Affairs*.

Anexos:

Anexo A: Estadística Descriptiva Completa (Dataset de Egresos)

Variables Incluidas	Count	Mean	Std	Min	50%	Max
MEDICOINTERV1, MEDICOALTA (ENCRIPADOS)	306.603	-	-	-	-	-
FECHA_NACIMIENTO, FECHA_INGRESO, FECHAALTA	306.603	1978 / 2024	-	1915	1977	2024
IR_29301_PESO	306.603	5.56	11.96	0.00	0.69	206.46
IR_29301_SEVERIDAD	306.603	1.45	1.01	0.00	1.00	3.00
DIAS_ESTADIA	306.603	5.69	12.13	0.00	2.00	661.00
USOSPABELLON	306.603	0.83	0.95	0.00	1.00	8.00
EDAD	306.603	46.06	25.53	0.00	47.00	109.00
COSTO_PROXY	306.603	98.18	770.31	0.00	1.91	136.470
PESORN1, RN1ESTADO	115.463	3165.84	668.34	100.0	3250.0	9730.0
PESORN2, RN2ESTADO	1.271	2247.13	622.54	200.0	2330.0	3960.0
PESORN3, RN3ESTADO	14	1669.85	612.61	100.0	1845.0	2315.0
PROCEDIMIENTO 8 al PROCEDIMIENTO 30	Varía	~89.0	~17.0	0.09	91.3	99.9

Tabla 5, Tabla descriptiva dataset egresos.

Anexo B: Validación de Supuestos Estadísticos

Validación de Supuestos Estadísticos

Antes de proceder con el análisis inferencial y el modelamiento, se verificaron los supuestos clásicos sobre la variable dependiente (IR_ 29301 PESO y COSTO PROXY) para asegurar la validez de los resultados.

Supuesto de Normalidad (Test de Shapiro-Wilk)

- **Observación:** Dado el gran tamaño de la muestra ($N = 1.048.015$), se analizó la distribución mediante histogramas de densidad y el test de Shapiro-Wilk.
- **Resultado:** El test arrojó un **p-valor** < 0.05 , rechazando la hipótesis nula de normalidad.
- **Interpretación:** Los datos presentan una **asimetría positiva extrema** (long tail) y una alta curtosis. Esto indica que los métodos paramétricos tradicionales (como el ANOVA) no son adecuados, justificando el uso del test de **Kruskal-Wallis** basado en rangos para el análisis de beneficiarios.

Supuesto de Homocedasticidad (Test de Levene)

- **Observación:** Se evaluó si la varianza del gasto es constante a través de los diferentes grupos de severidad y franjas etarias.
- **Resultado:** El test de Levene resultó significativo (**p-valor** < 0.001), indicando heterocedasticidad (varianzas desiguales).
- **Interpretación:** Esto es clínicamente coherente: los pacientes con severidad nivel 3 presentan una dispersión de costos mucho mayor que aquellos en el nivel 1. Este hallazgo refuerza la decisión de utilizar modelos robustos y pruebas no paramétricas.

Supuesto de Independencia y Multicolinealidad (VIF)

- **Observación:** En el modelo de regresión, se verificó la relación entre las variables independientes, especialmente entre DIAS ESTADIA y SEVERIDAD.
- **Resultado:** Aunque existe una correlación de **0.68** (Pearson), los factores de inflación de la varianza (VIF) se mantienen en niveles aceptables para el modelamiento, permitiendo cuantificar el impacto individual de cada variable.

- **Interpretación:** Se confirma que la estadía y la severidad, si bien están relacionadas, aportan información distinta al costo final del egreso.

Anexo C: Gráficos adicionales que respaldan la hipótesis.




Gráfico 4, Relación Peso-Estadía por Severidad.

Se observa una correlación positiva entre estadía y peso relativo, amplificada drásticamente en severidad 3 (línea roja). Mientras en severidad baja el costo es estable, en nivel 3 cada día adicional eleva significativamente el costo de producción. Esto ratifica que el perfil de alto costo depende tanto de la permanencia como de la intensidad clínica del paciente.




Gráfico 5, Incremento marginal del costo.

El incremento de costo más relevante ocurre al alcanzar el **nivel 3 de severidad**, especialmente en los grupos de **0-17** y **18-39** años. Este costo marginal no es lineal; el paso del nivel 2 al 3 genera un impacto financiero superior al de niveles previos. El mayor aumento absoluto se observa en 18-39 años, evidenciando el alto costo sistémico de sus patologías complejas.




Gráfico 6, Distribución regional según el sexo.

A nivel nacional, los hombres presentan un peso relativo promedio superior al de las mujeres, sugiriendo un mayor consumo masculino. Regiones como Antofagasta, Los Lagos y O'Higgins registran los promedios más altos, posiblemente vinculados a la presencia de centros de alta complejidad.




Gráfico 7, Boxplot Peso GRD por nivel de severidad.

Este gráfico de caja y bigotes evidencia cómo el consumo de recursos se dispara al aumentar la complejidad clínica. Mientras los niveles 0 y 1 son estables, el **Nivel 3 de severidad** presenta la mayor mediana y una dispersión masiva de valores atípicos (outliers), consolidándose como el principal factor clínico disruptivo del presupuesto.





Gráfico 8, Frecuencia de pesos relativos.

Se observa una asimetría positiva extrema. La gran mayoría de los casos se concentran cerca del promedio sistémico de 1.0, pero existe una "cola larga" de pacientes con pesos muy elevados que representan el objeto de estudio de esta investigación: los pacientes de alto costo.



G

Gráfico 9, Distribución de Sexo en Subgrupo de Alto Costo

Compara el volumen de egresos entre hombres y mujeres dentro del percentil de mayor gasto. Se observa una predominancia de los hombres, quienes presentan un peso relativo promedio superior a nivel nacional, sugiriendo un mayor consumo de recursos per cápita.




Gráfico 10, Top 12 comunas en subgrupo 1 (count).

Identifica los nodos geográficos de mayor presión asistencial. **Puente Alto y Maipú** lideran el conteo de egresos de alto costo, lo que se atribuye a su alta densidad poblacional y la presencia de centros de salud de alta complejidad.




Gráfico 11 y 12, Probabilidad de Peso Relativo > 1.0 por Franja Etaria

Analiza la probabilidad de que un paciente exceda el promedio de costo según su edad. Destaca que los adultos mayores (60 y más años) y los neonatos (0-1 años) tienen las probabilidades más altas, vinculando el costo a la fragilidad biológica en los extremos del ciclo vital.





Gráfico 13, Correlación de Pearson (Heatmap)

Mide la fuerza de la relación lineal entre variables. Destaca una correlación moderada-fuerte de 0.68 entre los días de estadía y el costo aproximado. Esto confirma que el tiempo de ocupación de cama es el predictor más robusto del gasto, por encima de variables como la edad (0.11).

Anexo D: Planificación, Metodología, Distribución de Tareas y Próximos Pasos

Para garantizar la finalización exitosa del proyecto y la robustez del análisis final, el equipo ha definido una estructura de trabajo colaborativo y un cronograma técnico detallado.

D.1. Diagrama metodológico



Imágen 1, Diagrama metodológico proyecto.

D.2. Distribución de Responsabilidades y Tareas

El trabajo se ha distribuido de manera equitativa, aprovechando las fortalezas técnicas de cada integrante para asegurar la calidad tanto del informe escrito como del repositorio de código.

Responsable	Áreas de Gestión	Tareas Específicas
Josefa Lara	Análisis Estadístico e Inferencia	Ejecución de tests de hipótesis (Kruskal-Wallis), validación de supuestos, y ajuste del modelo de regresión lineal múltiple en Python.

Catalina Toledo	Ingeniería de Datos y Documentación	Limpieza y preparación de datos (Data Engineering), gestión del repositorio de código, redacción técnica del informe y visualizaciones (EDA).
Equipo Conjunto	Interpretación y Discusión	Integración de hallazgos clínicos con resultados estadísticos, redacción de la discusión final y preparación de la presentación oral.

Tabla 5, Distribución de responsabilidades.

D.3. Cronograma de Actividades para el Avance Final

Este plan contempla la profundización del análisis actual y la resolución de las limitaciones identificadas en el Avance 2.

Fase	Actividad Técnica	Objetivo	Fecha Estimada
Optimización	Inclusión de Interacciones	Evaluar la interacción entre DIAS ESTADIA y SEVERIDAD para mejorar el R^2 del modelo.	Semana 6
Validación	Test de Multicolinealidad	Calcular el Factor de Inflación de la Varianza (VIF) para asegurar la independencia de los predictores.	Semana 7
Profundización	Análisis Regional Detallado	Investigar factores logísticos en zonas extremas (Aysén/Tarapacá) que expliquen los coeficientes de costo más altos.	Semana 8

Síntesis	Guía de Recomendaciones	Traducir los hallazgos en propuestas concretas para la gestión de recursos hospitalarios públicos.	Semana 9
Finalización	Revisión y Formato	Consolidación final del informe (APA), limpieza del repositorio y ensayo de la defensa oral.	Semana 10

Tabla 6, Cronograma de Actividades para Avance 2.

Anexo E: Peso relativo sobre el promedio muestral

Variable	Coeficiente	OR
HOMBRE	0.458138	1.581127
EDAD_z	0.388861	1.475300
RG_Aysén	0.301874	1.352391
RG_Magallanes	0.292465	1.339726
RG_Metropolitana	0.220587	1.246808
RG_Valparaíso	0.187106	1.205756
RG_Los Ríos	0.114860	1.121716
RG_Biobío	0.092065	1.096436
RG_O'Higgins	0.070107	1.072623
RG_Maule	0.058826	1.060591
RG_Los Lagos	0.043174	1.044120
RG_Tarapacá	0.040168	1.040986
RG_Coquimbo	0.011004	1.011065
RG_Atacama	-0.000121	0.999879
RG_La Araucanía	-0.089674	0.914229
RG_Ñuble	-0.097061	0.907501
RG_Arica y Parinacota	-0.143572	0.866258
FR_2-17	-0.396182	0.672884
FR_60 y más	-0.518230	0.595573

Variable	Coeficiente	OR
FR_40–59	-0.553459	0.574958
FR_18–39	-1.169020	0.310671

Tabla, Regresión logística sobre submuestra balanceada (robusta a coste computacional)

Anexo F: Combinaciones de sexo, rango etario en comparación a su peso GRD




Gráfico. Medianas de Peso GRD según por rango etario x sexo.