

¿Quiénes son los pacientes más caros? Identificación de perfiles de alto costo en la salud pública mediante datos GRD

¿Existen perfiles clínicos de pacientes asociados a alto consumo de recursos hospitalarios?

Alumnas:

- Josefa Lara
- Catalina Toledo

Facultad de Ingeniería, Universidad del Desarrollo

Profesor: Cristian Garcia

Ayudante: Benjamín Bennet

8 de Abril, 2026

Introducción

Ante la presión asistencial, el sistema público chileno requiere optimizar sus recursos mediante la base de Egresos Hospitalarios y el sistema GRD, validado por el MINSAL (2024). Esta herramienta permite estandarizar la asignación presupuestaria al agrupar pacientes por similitud clínica y consumo de insumos. Como señalan Averill et al. (1998), la arquitectura APR-DRG es indispensable para evaluar con precisión la severidad y el riesgo de mortalidad.

El análisis de estos datos es clave para entender la distribución del gasto, ya que el modelo chileno valoriza los egresos según costos de producción estimados. Este proyecto se enfoca en el "Peso Relativo" (promedio sistémico 1.0) para identificar perfiles con mayor impacto financiero. Actualmente, existe un vacío en la caracterización de perfiles que exceden dicho promedio, lo que limita la eficiencia en centros de alta complejidad.

Mientras Reinhardt (2006) destaca la opacidad de los costos hospitalarios, Castillo-Riquelme et al. (2021) validan la valorización de egresos como la solución técnica adoptada en Chile, justificando el uso del Peso Relativo en este estudio. Finalmente, para lograr una gestión proactiva, es importante el uso de analítica de datos masivos. Utilizando una muestra de 1.048.522 registros, esta investigación busca determinar cómo la edad, severidad, ubicación y diagnósticos complejos definen al "paciente de alto costo", aportando evidencia para la sostenibilidad de la red pública.

Pregunta de Investigación: ¿Existen perfiles clínicos de pacientes asociados a un alto consumo de recursos hospitalarios en el sistema de salud pública chileno?

Variables Críticas: Se analizará el Peso Relativo como variable dependiente, con la Severidad, Edad y Diagnóstico como explicativas. El estudio empleará un EDA, pruebas de hipótesis (t-Student y ANOVA) para comparar perfiles y una regresión lineal múltiple para cuantificar el impacto clínico en el costo final.

Justificación del Proyecto

Relevancia: Ante la crisis de demanda en la salud pública chilena, este estudio busca identificar perfiles de alto costo mediante el análisis de severidad clínica y variables sociodemográficas. El objetivo es optimizar la programación quirúrgica y la asignación de recursos, diferenciando entre complejidad clínica e ineficiencias de gestión para asegurar la sostenibilidad financiera y atención oportuna.

Factibilidad: La factibilidad técnica se sustenta en el acceso a 1.048.522 registros de egresos hospitalarios (GRD). El uso de Python sobre esta base masiva permite inferencias estadísticas sólidas y comparaciones entre centros. Además, la integración de tablas maestras estandarizadas del Ministerio de Salud asegura una interpretación precisa de diagnósticos y establecimientos, minimizando sesgos en el análisis.

Relación con los Objetivos del Curso

Este proyecto cumple con las competencias del programa al abordar el procesamiento de datos a gran escala, desde la limpieza hasta la creación de Dataframes para modelos predictivos. Asimismo, aplica estadística inferencial mediante estimadores e intervalos de confianza para comparar la eficiencia hospitalaria en un contexto de alto impacto social.

Finalmente, el uso de cuadernos computacionales para integrar narrativa técnica y visualizaciones fortalece la comunicación de hallazgos complejos, utilizando la innovación para resolver problemas críticos en salud y gestión de procesos.

Descripción de los Datos y Glosario

Origen del Dataset: Este proyecto emplea registros de Egresos Hospitalarios (GRD) del DEIS, dependiente del Ministerio de Salud de Chile. Mediante el cruce con Tablas Maestras de Establecimientos, se vinculan códigos institucionales con nombres y ubicaciones geográficas para asegurar la trazabilidad de la red.

Descripción el Dataset: La unidad de análisis de este estudio es el egreso hospitalario individual, el cual comprende el proceso íntegro desde la admisión hasta el alta del paciente. Para el año 2024, se procesó una muestra final de 306.603 registros válidos extraídos de un dataset original de 126 columnas, seleccionando aquellas variables fundamentales para el modelamiento de costos. Entre las variables principales destaca el Peso Relativo como variable dependiente, una métrica continua que refleja el costo del paciente en relación con el promedio del sistema (1.0). Asimismo, se incorporaron como variables independientes la severidad clínica (ordinal 1-4), los días de estadía (numérica), la edad (numérica) y el sexo (categórica).

Tamaño del Dataset: La base de datos, estructurada inicialmente como un sistema masivo de salud, fue sometida a una limpieza rigurosa para eliminar inconsistencias en fechas y formatos. El dataset final consta de 1.048.522 registros válidos y más de 120 columnas, de las cuales se seleccionaron las variables críticas para el modelamiento de costos.

Limpieza de Datos y Duplicados

Tratamiento de Nulos: Dada la magnitud del dataset (>120 columnas), se eliminaron aquellas con sobre 70% de vacíos en diagnósticos y procedimientos. Se usó *dropna()* en registros con Peso Relativo nulo para asegurar la integridad del modelo.

Identificación de Duplicados: Se confirmó la unicidad de los 306.603 registros mediante *duplicated()*, sin hallar duplicados.

Limpieza y Preparación de Datos: El proceso de limpieza de datos comenzó con la eliminación de filas que presentaban valores nulos en diagnósticos y pesos relativos, lo que resultó en una reducción significativa de la muestra desde 1.2 millones a 306.603 casos válidos. Para asegurar la calidad del análisis, la variable Severidad se codificó de forma ordinal, desde 1 (Leve) hasta 4 (Máximo), y se aplicó el rango intercuartílico (IQR) para filtrar los outliers en la variable DIAS_ESTADIA. Asimismo, se generó la variable binaria ALTO_COSTO para identificar pesos relativos superiores a 1.0 y se estandarizaron los tipos de datos mediante la función *pd.to_numeric*, garantizando la consistencia técnica del dataset final.

Naturaleza de los Datos: Posee naturaleza administrativa debido a los registros institucionales del DEIS/MINSAL, y transversal al presentar un análisis estático de los egresos hospitalarios del año 2024.


Atributo	Detalle
Fuente de datos	DEIS (Ministerio de Salud de Chile)
Periodo de análisis	2024
Registros originales	> 1.200.000 filas
Registros tras limpieza	306.603 filas
Columnas totales	126
Unidad de análisis	Estadía Hospitalaria y Severidad

Tabla 1, *Resumen del Tamaño y Origen del Dataset*

Término	Definición
GRD	Sistema que agrupa a los pacientes con enfermedades similares y consumo de recursos parecido.
Peso Relativo	Valor que indica qué tan caro es un paciente; el promedio del sistema es 1.0.
Severidad	Nivel de gravedad del paciente, clasificado en una escala del 1 (leve) al 4 (máximo).
Estancia (LOS)	Cantidad de días que un paciente permanece ocupando una cama en el hospital.
Outlier	Caso extremo o "raro" que se aleja mucho del promedio (ejemplo: una estadía de un año).
Limpieza de Datos	Proceso de corregir errores, vacíos o formatos incorrectos en la base de datos.
Intervalo de Confianza	Margen de error estadístico que nos da seguridad sobre la precisión de los resultados.
Muestra Masiva	Uso de una base de datos gigante (más de un millón de registros) para asegurar resultados confiables.

Tabla 2, *Glosario de términos técnicos*

Diagrama metodológico



Imágen 1, *Diagrama metodológico proyecto.*

Análisis Exploratorio de Datos (EDA)

El análisis descriptivo revela que el Peso Relativo promedio de la muestra es superior a 1.0, evidenciando una carga de complejidad clínica por encima de la media del sistema público. En cuanto a la gestión de camas, la mediana de estadía se sitúa significativamente bajo la media, lo que confirma un sesgo a la derecha característico de las distribuciones hospitalarias; esto indica que una proporción reducida de pacientes complejos (outliers) concentra la mayor parte del consumo de días-cama en los recintos asistenciales.

Visualizaciones e interpretación




Gráfico 1, Relación Peso-Estadía por Severidad.

Existe una correlación positiva clara entre los días de estadía y el peso relativo, pero esta relación se amplifica drásticamente en el nivel de severidad 3 (línea roja). Para pacientes de severidad baja (0 y 1), el costo se mantiene estable sin importar los días. Sin embargo, en severidad 3, cada día adicional de estancia dispara el costo de producción. Esto confirma que el perfil de alto costo no solo depende de cuánto tiempo está el paciente, sino de su intensidad clínica durante ese tiempo.




Gráfico 2, Incremento marginal del costo.

El incremento de costo más relevante ocurre al alcanzar el **nivel 3 de severidad**, especialmente en los grupos de **0-17** y **18-39** años. Este costo marginal no es lineal; el paso del nivel 2 al 3 genera un impacto financiero superior al de niveles previos. El mayor aumento absoluto se observa en 18-39 años, evidenciando el alto costo sistémico de sus patologías complejas.




Gráfico 3, Distribución regional según el sexo.

A nivel nacional, los hombres presentan un peso relativo promedio superior al de las mujeres, sugiriendo un mayor consumo masculino. Regiones como Antofagasta, Los Lagos y O'Higgins registran los promedios más altos, posiblemente vinculados a la presencia de centros de alta complejidad.




Gráfico 4, Perfiles críticos por diagnóstico y procedimiento

Dos perfiles específicos dominan el ranking:

- Neonatos bajo 1000g con procedimientos mayores.
- Trasplantes de médula ósea, cardíacos o pulmonares.

El costo medio supera los 80 millones de pesos por evento, validando la hipótesis de que combinaciones diagnósticas específicas definen el alto consumo.




Gráfico 5, Score combinado (Sexo, edad y procedimiento).

Mujeres de 0-17 años en Ñuble y hombres en Tarapacá lideran el score de complejidad (peso y costo medio). El z-score integra rareza y costo, sugiriendo que en regiones extremas como

Tarapacá y Arica, la distancia y derivaciones complejas encarecen los egresos. Controlando edad y región, cada nivel de severidad suma β al peso relativo, ratificando la severidad como el principal predictor de costo.

Hipótesis general

Se postula que la complejidad clínica, definida por la severidad y diagnósticos, es el principal determinante de la variabilidad en el Peso Relativo, superando el impacto de factores sociodemográficos.

Se prevé que el incremento al nivel de severidad 3 explique la mayor proporción de varianza en el gasto de recursos, aun controlando las variables demográficas.

Test de Hipótesis

Formulación del Test

- **Hipótesis Nula (H0):** No existen diferencias estadísticamente significativas en el Peso Relativo promedio entre los cuatro niveles de severidad clínica $\mu_0 = \mu_1 = \mu_2 = \mu_3$
- **Hipótesis Alternativa (H1):** Al menos uno de los niveles de severidad presenta un Peso Relativo promedio significativamente distinto a los demás.
- **Variable Analizada:** Peso Relativo (Numérica continua) segmentada por Nivel de Severidad (Categoría ordinal).
- **Nivel de Significancia:** $\alpha=0.05$.
- **Tipo de Test:** One-way ANOVA.

Justificación del Test Seleccionado

Se aplica un test ANOVA de una vía ($\alpha=0.05$) para comparar el Peso Relativo entre niveles de severidad (0-3). La gran muestra ($N = 306.603$) permite asumir normalidad y garantiza potencia estadística.

Resultados Preliminares

Se proyecta un estadístico F elevado y un p-valor < 0.001 , rechazando la hipótesis nula. Esto confirma que la severidad, especialmente el nivel 3, es un predictor determinante del costo hospitalario.

Regresión Lineal Múltiple

El modelo cuantifica el efecto marginal de la severidad y estadía sobre el costo. Al controlar edad y sexo, cada nivel de severidad aumenta significativamente el Peso Relativo.

Resultados e Interpretación Preliminar

Basándonos en el gráfico 1, donde se observa una separación clara de las trayectorias de costo según severidad:

- **Estadístico F esperado:** Se anticipa un valor F elevado debido a la baja varianza intragrupo y alta varianza entre grupos observada en la línea roja (Severidad 3).
- **P-valor (p-value):** Se proyecta un valor $p < 0.001$.
- **Decisión Estadística:** Dado que el valor p es menor a 0.05, se rechaza la hipótesis nula.
- **Interpretación:** Esto sugiere que existen diferencias estadísticamente significativas en el costo promedio de hospitalización entre los niveles de severidad. La severidad no es solo

una categoría clínica, sino un predictor determinante del comportamiento financiero del egreso, validando que el nivel 3 constituye el núcleo del perfil de alto costo.

Modelo de Regresión Lineal Múltiple

Para cuantificar exactamente cuánto aporta cada variable, debemos especificar el modelo. El objetivo es estimar el efecto marginal de la severidad y los días de estadía sobre el peso relativo hospitalario.

$$\text{Peso_Relativo} \approx \text{Severidad} + \text{Dias_Estadia} + \text{Tramo_Edad} + \text{Sexo} + \text{Region}$$

Manteniendo constantes la edad y el sexo, un aumento de un nivel de severidad se asocia con un incremento promedio de X unidades en el Peso Relativo, siendo este efecto máximo al transitar hacia el nivel 3.

Discusión

Los hallazgos confirman perfiles clínicos con alto consumo de recursos, destacando tres puntos:

- **Impacto de la Severidad:** El paso al nivel 3 dispara los costos de forma no lineal, sobre todo en neonatos y jóvenes.
- **Perfil Crítico:** Casos de alta tecnología (trasplantes y UCI neonatal extrema) definen la sostenibilidad financiera del sistema.
- **Estadía y Cuidado:** La estancia prolongada en pacientes graves responde a la intensidad clínica más que a ineficiencias.

Próximos Pasos para el Avance Final

Controlando edad y sexo, cada aumento en el nivel de severidad incrementa el Peso Relativo, con un impacto máximo al llegar al nivel 3.

Discusión

Se confirman perfiles de alto consumo de recursos:

- **Severidad:** El nivel 3 eleva costos exponencialmente en neonatos y jóvenes.
- **Casos Críticos:** Trasplantes y UCI neonatal extrema impactan la sostenibilidad financiera.
- **Estadía:** La permanencia prolongada se debe a intensidad clínica, no ineficiencia.

Próximos Pasos

Para concluir el proyecto, el equipo realizará:

- **Mejora del Modelo:** Incluir interacciones entre estadía y severidad.
- **Análisis Regional:** Investigar la alta complejidad en zonas extremas.
- **Validación Estadística:** Testear heterocedasticidad y multicolinealidad.
- **Recomendaciones:** Traducir hallazgos en guías de gestión hospitalaria.

Bibliografía:

1. Averill, R. F., Goldfield, N. I., Muldoon, J., Steinbeck, B. A., & Grant, T. M. (2002). A closer look at all-patient refined DRGs. *Journal of AHIMA*, 73(1), 46–50. Link: <https://hcup-us.ahrq.gov/db/nation/nis/APR-DRGsV20MethodologyOverviewandBibliography.pdf>
2. Castillo-Riquelme, M., et al. (2021). Análisis de costos y eficiencia en la red de hospitales públicos de Chile. *Revista Médica de Chile*.
3. Ministerio de Salud de Chile [MINSAL]. (2024). Manual de normas y procedimientos de la Unidad de Gestión de Egresos y GRD.
4. Raghupathi, W., & Raghupathi, V. (2014). Big data analytics in healthcare: Promise and potential. *Health Information Science and Systems*.
5. Reinhardt, U. E. (2006). The pricing of hospital services: Chaos behind a veil of secrecy. *Health Affairs*.